TSIFRA S.R.L.
Revista de Investigación Interdisciplinaria (demo)
Vol. 1, n.º 1 (2025)
pp. 9–11 · ISSN 0000-0000 (en línea)

ARTÍCULO DE INVESTIGACIÓN

Calibración mediante aprendizaje automático de sensores de PM2.5 de bajo coste en un clima marcadamente continental

Timur Karimov[1✉], **Olga Vasilenko**[2]

[1] Instituto de Analítica Aplicada del Volga, Rusia
[2] Instituto de Investigación en Salud Pública Vita, Rusia
✉ Autor de correspondencia: Timur Karimov, t.karimov@example.org

Recibido: 30 de septiembre de 2024 **Aceptado:** 3 de febrero de 2025 **Publicado:** 20 de marzo de 2025

RESUMEN

Los sensores ópticos de bajo coste de partículas finas pueden aumentar considerablemente la densidad de las redes de monitorización de la calidad del aire, pero sus lecturas dependen en gran medida de la humedad y la temperatura y se desvían sistemáticamente de las mediciones de referencia. Este estudio compara métodos de calibración de dichos sensores en un clima marcadamente continental con una gran amplitud térmica anual. Durante 14 meses se coubicaron ocho sensores con una estación de referencia gravimétrica, lo que proporcionó más de 76 000 observaciones horarias. Se compararon la regresión lineal, la regresión múltiple con corrección por humedad relativa, el bosque aleatorio y el potenciado de gradiente (gradient boosting). El rendimiento se evaluó mediante validación cruzada por bloques semanales, que impide la fuga de información entre las muestras de entrenamiento y de prueba. Sin calibración, el error absoluto medio fue de 11,8 µg/m³; tras la corrección lineal descendió a 6,4 µg/m³, y el potenciado de gradiente lo redujo a 3,1 µg/m³. Las variables más importantes fueron la humedad relativa, la temperatura y las lecturas de los sensores vecinos. Los modelos entrenados únicamente con datos de verano se transfirieron mal al periodo invernal, lo que subraya la necesidad de una calibración durante todo el año. Concluimos que, una vez calibrados con métodos de aprendizaje automático, los sensores de bajo coste son adecuados para evaluar la dinámica diaria de la contaminación e identificar fuentes locales. El código y los datos anonimizados están disponibles en abierto para su reutilización.

Palabras clave: calidad del aire; PM2.5; sensores de bajo coste; calibración; potenciado de gradiente

Machine-Learning Calibration of Low-Cost PM2.5 Sensors in a Sharply Continental Climate

Timur Karimov[1✉], *Olga Vasilenko*[2]

[1] Volga Institute of Applied Analytics, Russia
[2] Vita Research Institute of Public Health, Russia

ABSTRACT

Low-cost optical sensors of fine particulate matter can substantially increase the density of air-quality monitoring networks, but their readings depend strongly on humidity and temperature and deviate systematically from reference measurements. This study compares calibration methods for such sensors in a sharply continental climate with a large annual temperature range. For 14 months, eight sensors were co-located with a gravimetric reference station, yielding more than 76,000 hourly observations. Linear regression, multiple regression with a relative-humidity correction, random forest and gradient boosting were compared. Performance was assessed with weekly blocked cross-validation that prevents information leakage between training and test samples. Without calibration, the mean absolute error was 11.8 µg/m³; after linear correction it fell to 6.4 µg/m³, and gradient boosting reduced it to 3.1 µg/m³. The most important features were relative humidity, temperature and the readings of neighbouring sensors. Models trained on summer data alone transferred poorly to the winter period, underlining the need for year-round calibration. We conclude that, once calibrated with machine-learning methods, low-cost sensors are suitable for assessing the diurnal dynamics of pollution and identifying local sources. The code and anonymised data are openly available for reuse.

Publicado bajo licencia CC BY 4.0

Keywords: air quality; PM2.5; low-cost sensors; calibration; gradient boosting

Cómo citar: Karimov T., Vasilenko O. Calibración mediante aprendizaje automático de sensores de PM2.5 de bajo coste en un clima marcadamente continental. *Revista de demostración en Open Journal Systems* 2025;1(1):9–11.

1 INTRODUCCIÓN

Las partículas finas PM2.5 son uno de los principales factores de riesgo para la salud asociados a la contaminación del aire ambiente. Las estaciones de monitorización de referencia son caras y escasas: en una ciudad típica de medio millón de habitantes hay una o dos. Los sensores ópticos de bajo coste, que cuestan unos pocos miles de rublos, permiten crear una red densa, pero sus lecturas requieren calibración.

La principal causa de error es el crecimiento higroscópico de las partículas con humedad elevada, que hace que el sensor sobrestime la concentración másica. En un clima marcadamente continental se suman a ello las bajas temperaturas invernales, que afectan al funcionamiento de la electrónica. El objetivo del trabajo es comparar métodos de calibración y evaluar su transferibilidad entre estaciones del año.

2 MATERIALES Y MÉTODOS

Se instalaron ocho sensores del mismo modelo en el techo de la caseta de la estación de referencia, a 3 m de altura. El periodo de observación se extendió de octubre de 2022 a noviembre de 2023. Los datos se agregaron a valores horarios; se excluyeron las horas con registros incompletos (menos de 45 minutos). La muestra final consta de 76 412 pares de observaciones.

Se compararon cuatro modelos: regresión lineal simple sobre la señal bruta; regresión múltiple con humedad relativa, temperatura y su interacción; bosque aleatorio (500 árboles); potenciado de gradiente (profundidad 6, tasa de aprendizaje 0,05). Para evaluar el rendimiento se utilizó validación cruzada por bloques: los datos se dividieron en bloques semanales y cada bloque sirvió sucesivamente como muestra de prueba.

3 RESULTADOS

Los resultados de la comparación se presentan en la tabla 1 y en la figura 1. Todos los métodos de calibración reducen considerablemente el error; la diferencia entre la regresión lineal con corrección por humedad y los métodos de conjunto es especialmente grande con humedades relativas superiores al 80 %.

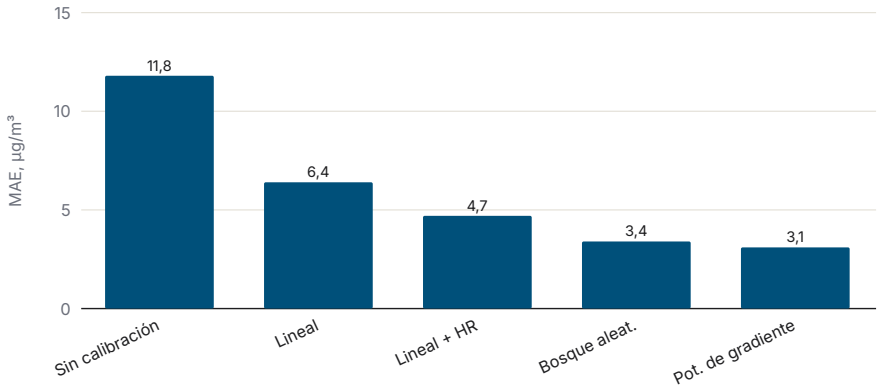


Fig. 1. Error absoluto medio (MAE) de los distintos métodos de calibración, µg/m³

Cuando el modelo se entrenaba solo con datos de verano y se evaluaba con datos de invierno, el error absoluto medio del potenciado de gradiente aumentaba hasta 7,9 µg/m³, apenas algo mejor que la corrección lineal. La inclusión en la muestra de entrenamiento de al menos un mes de invierno reducía el error a 3,6 µg/m³.

Publicado bajo licencia CC BY 4.0

Tabla 1. Rendimiento de los métodos de calibración (validación cruzada por bloques semanales)

Método	MAE, µg/m³	RMSE, µg/m³	R^2
Sin calibración	11,8	17,2	0,58
Regresión lineal	6,4	9,9	0,74
Lineal + humedad	4,7	7,3	0,85
Bosque aleatorio	3,4	5,6	0,91
Potenciado de gradiente	3,1	5,1	0,93

4 DISCUSIÓN

Los valores de error obtenidos tras la calibración son comparables a las tolerancias de las mediciones indicativas y permiten utilizar la red de sensores de bajo coste para estimar perfiles diarios e identificar fuentes locales: salas de calderas, autopistas o zonas de viviendas unifamiliares con calefacción de estufa.

La falta de transferibilidad estacional de los modelos es una limitación práctica importante. Una calibración realizada en verano puede producir errores sistemáticos en invierno, cuando la contaminación es más peligrosa. Recomendamos un periodo de mediciones conjuntas de al menos un año antes del despliegue de la red.

5 CONCLUSIONES

Los métodos de aprendizaje automático de conjunto reducen casi a la cuarta parte el error de los sensores de PM2.5 de bajo coste. La condición clave para una calibración correcta es que la muestra de entrenamiento incluya datos de todas las estaciones del año.

REFERENCIAS

1. Breiman L. Random forests // Machine Learning. 2001. Vol. 45, no. 1. P. 5–32.
2. Friedman J. H. Greedy function approximation: a gradient boosting machine // Annals of Statistics. 2001. Vol. 29, no. 5. P. 1189–1232.
3. Каримов Т. Р. Блочная кросс-валидация для пространственно-временных данных: практическое руководство // Прикладная аналитика. 2022. Т. 6, № 3. С. 41–58.
4. Holloway R., Nakamura E. Humidity effects on optical particle counters: a field evaluation // Atmospheric Measurement Notes. 2019. Vol. 12. P. 233–248.
5. Василенко О. П., Аркадьева Н. С. Кратковременное воздействие PM2.5 и обращаемость за медицинской помощью: обзор исследований // Экология человека и среда. 2021. № 7. С. 4–19.
6. Petrescu D., Olsen K. Transferability of calibration models for low-cost air sensors across seasons // Environmental Sensing Review. 2022. Vol. 4, no. 2. P. 77–95.
7. Захаров Л. Е. Сети мониторинга атмосферного воздуха: принципы проектирования. Новобор: Академия, 2020. 184 с.

Publicado bajo licencia CC BY 4.0