TSIFRA S.R.L.
Revista de Investigación Interdisciplinaria (demo)
Vol. 2, n.º 1 (2026)
pp. 8–10 · ISSN 0000-0000 (en línea)

ARTÍCULO DE INVESTIGACIÓN

Detección de fragmentos generados automáticamente en resúmenes científicos en lengua rusa

Timur Karimov[1], **Anna Lebedeva**[2], **Sanzhar Abdullaev**[3]✉

[1] Instituto de Analítica Aplicada del Volga, Rusia
[2] Instituto de Lengua y Comunicación Lexis, Rusia
[3] Instituto de Lingüística Computacional de Samarcanda, Uzbekistán
✉ Autor de correspondencia: Sanzhar Abdullaev, s.abdullaev@example.org

Recibido: 18 de agosto de 2025 **Aceptado:** 27 de enero de 2026 **Publicado:** 18 de marzo de 2026

RESUMEN

La adopción generalizada de los grandes modelos de lenguaje ha enfrentado a las revistas científicas a la tarea de identificar textos creados total o parcialmente por medios automáticos. La mayoría de los detectores existentes se desarrollaron para el inglés, y su aplicabilidad a los textos científicos en ruso apenas se conoce. Este artículo presenta un nuevo corpus anotado de 12 000 resúmenes de artículos científicos en ruso, la mitad de los cuales fueron escritos por personas y la otra mitad contiene fragmentos generados por tres modelos de lenguaje distintos con instrucciones diferentes. En este corpus se comparan cuatro clases de métodos: rasgos estadísticos de perplejidad, rasgos estilométricos, un clasificador basado en transformers ajustado (fine-tuned) y un detector comercial de uso general. El clasificador ajustado obtuvo los mejores resultados (F1 = 0,91 a nivel de documento), pero su rendimiento cayó a 0,74 al evaluarlo con textos generados por un modelo no visto durante el entrenamiento. A nivel de oración, todos los métodos funcionan considerablemente peor, y la tasa de falsos positivos en resúmenes escritos por autores cuya lengua materna no es el ruso alcanza el 11 %. Estos resultados indican que los detectores automáticos no pueden servir como única base para las decisiones editoriales. El corpus y el código están disponibles en abierto para futuras investigaciones.

Palabras clave: grandes modelos de lenguaje; detección de texto generado automáticamente; resúmenes científicos; lengua rusa; integridad científica

Detecting Machine-Generated Passages in Russian-Language Scientific Abstracts

Timur Karimov[1], *Anna Lebedeva*[2], *Sanzhar Abdullaev*[3]✉

[1] Volga Institute of Applied Analytics, Russia
[2] Lexis Institute of Language and Communication, Russia
[3] Samarkand Institute of Computational Linguistics, Uzbekistan

ABSTRACT

The widespread adoption of large language models has confronted scholarly journals with the task of identifying texts created wholly or partly by automated means. Most existing detectors were developed for English, and their applicability to Russian-language scientific texts is poorly understood. This article presents a new annotated corpus of 12,000 abstracts of scientific articles in Russian, half of which were written by humans and half of which contain passages generated by three different language models under different prompts. Four classes of methods are compared on this corpus: statistical perplexity features, stylometric features, a fine-tuned transformer-based classifier and a general-purpose commercial detector. The fine-tuned classifier performed best (document-level F1 = 0.91), but its performance fell to 0.74 when tested on texts generated by a model not seen during training. At the sentence level, all methods perform considerably worse, and the false-positive rate on abstracts written by authors for whom Russian is not a first language reaches 11%. These results indicate that automated detectors cannot serve as the sole basis for editorial decisions. The corpus and code are openly available for further research.

Keywords: large language models; machine-generated text detection; scientific abstracts; Russian language; research integrity

Publicado bajo licencia CC BY 4.0

Cómo citar: Karimov T., Lebedeva A., Abdullaev S. Detección de fragmentos generados automáticamente en resúmenes científicos en lengua rusa. *Revista de demostración en Open Journal Systems* 2026;2(1):8–10.

1 INTRODUCCIÓN

Desde 2023, los editores de revistas científicas se encuentran cada vez con más frecuencia con manuscritos en los que partes del texto parecen haber sido producidas por grandes modelos de lenguaje. Aunque el uso de estas herramientas para la corrección lingüística suele ser aceptable, la generación no declarada de contenido sustantivo suscita preocupaciones sobre la integridad científica. Muchas editoriales han adoptado políticas que exigen declararlo, y se comercializan detectores automáticos como medio para hacerlas cumplir.

Sin embargo, estos detectores se han desarrollado y evaluado principalmente con textos en inglés. El ruso, con su rica morfología y su registro académico particular, plantea un reto distinto. Los objetivos de este estudio son construir un banco de pruebas realista de resúmenes científicos en ruso y evaluar el rendimiento de los métodos de detección actuales sobre él, con especial atención a la generalización y la equidad.

2 MATERIALES Y MÉTODOS

Los resúmenes escritos por personas (n = 6000) se muestrearon de revistas rusas de acceso abierto publicadas antes de 2021, estratificados en ocho grandes disciplinas. Para la mitad generada, se pidió a tres modelos de lenguaje que escribieran un resumen completo a partir de un título y unas palabras clave, que continuaran una frase inicial escrita por una persona o que parafrasearan un resumen escrito por una persona. Un anotador comprobó la fluidez de cada texto generado, y en los textos mixtos se registraron etiquetas a nivel de oración.

Comparamos (i) una regresión logística sobre rasgos de perplejidad y de irregularidad (burstiness) calculados con un modelo de lenguaje abierto para el ruso, (ii) un clasificador de potenciado de gradiente sobre 140 rasgos estilométricos, (iii) un codificador transformer multilingüe ajustado con la partición de entrenamiento y (iv) un detector comercial de uso general. Para evaluar la generalización se utilizó un protocolo de exclusión de un generador (leave-one-generator-out).

3 RESULTADOS

Los resultados a nivel de documento se resumen en la tabla 1. El clasificador ajustado obtuvo el mayor F1 dentro de la distribución, 0,91, seguido del modelo de perplejidad (0,82). El detector comercial, no entrenado con textos científicos en ruso, alcanzó 0,69. Los resúmenes parafraseados fueron la categoría más difícil para todos los métodos.

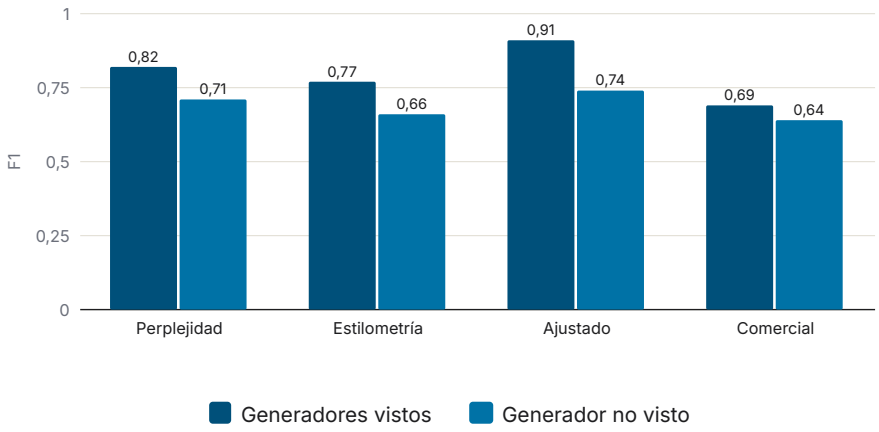


Fig. 1. F1 a nivel de documento dentro de la distribución y con un generador no visto

La generalización a un generador no visto redujo considerablemente el rendimiento (fig. 1). En un conjunto independiente de 400 resúmenes escritos por autores para quienes el ruso es una segunda lengua, el clasificador ajustado marcó el 11 % como generados automáticamente, frente al 3 % en los resúmenes de hablantes nativos.

Publicado bajo licencia CC BY 4.0

Tabla 1. Rendimiento de la detección a nivel de documento y de oración

Método	F1 (doc.)	F1 (oración)	TFP, autores L2
Rasgos de perplejidad	0.82	0.61	0.14
Rasgos estilométricos	0.77	0.55	0.09
Transformer ajustado	0.91	0.68	0.11
Detector comercial	0.69	—	0.17

4 DISCUSIÓN

Nuestros resultados coinciden con las preocupaciones planteadas para el inglés: los detectores que funcionan bien con generadores conocidos empeoran con los nuevos y marcan de forma desproporcionada los textos de autores no nativos, cuya prosa tiende a ser léxicamente menos variada. Dado el rápido lanzamiento de nuevos modelos, la precisión dentro de la distribución es una mala guía de la fiabilidad en condiciones reales.

Para la práctica editorial, esto implica que las puntuaciones de los detectores deberían, como mucho, dar pie a una conversación con los autores, y no desencadenar sanciones. Las políticas de declaración claras y la atención a la calidad científica sustantiva siguen siendo salvaguardas más sólidas.

5 CONCLUSIONES

Publicamos un banco de pruebas de 12 000 resúmenes científicos en ruso y mostramos que los detectores actuales, aunque útiles, no son robustos frente a nuevos generadores ni equitativos con los autores no nativos. La detección automática debe complementar el juicio editorial, no sustituirlo.

REFERENCIAS

1. Vaswani A., Shazeer N., Parmar N. et al. Attention is all you need // Advances in Neural Information Processing Systems. 2017. Vol. 30. P. 5998–6008.
2. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: pre-training of deep bidirectional transformers for language understanding // Proceedings of NAACL-HLT 2019. Minneapolis, 2019. P. 4171–4186.
3. Abdullaev S. R. Perplexity-based detection of generated text in morphologically rich languages // Computational Linguistics Letters. 2024. Vol. 9, no. 1. P. 22–37.
4. Lebedeva A. V., Karimov T. R. Stylometric profiles of Russian academic prose // Corpus Methods Quarterly. 2023. Vol. 14, no. 3. P. 201–219.
5. Moreau C., Banerjee R. Generalisation failures of machine-generated text detectors // Journal of AI Evaluation. 2024. Vol. 3. P. 77–96.
6. Каримов Т. Р., Лебедева А. В. Языковые модели в научной коммуникации: риски и редакционные политики // Научный редактор и издатель. 2024. Т. 9, № 2. С. 112–125.
7. Holt E., Nguyen T. Bias of AI-text detectors against non-native writers // Language and Technology Review. 2023. Vol. 12, no. 4. P. 300–318.
8. Абдуллаев С. Р. Корпусы для оценки детекторов сгенерированного текста: требования и практика // Вычислительная лингвистика и интеллектуальные технологии. 2025. Т. 4, № 1. С. 15–30.

Publicado bajo licencia CC BY 4.0