SARL TSIFRA
Revue de recherche interdisciplinaire (démo)
Vol. 2, nº 1 (2026)
p. 8–10 · ISSN 0000-0000 (en ligne)

ARTICLE DE RECHERCHE

Détection de passages générés automatiquement dans les résumés scientifiques en langue russe

Timur Karimov[1], **Anna Lebedeva**[2], **Sanzhar Abdullaev**[3]✉

[1] Institut d'analytique appliquée de la Volga, Russie
[2] Institut de langue et de communication « Lexis », Russie
[3] Institut de linguistique computationnelle de Samarcande, Ouzbékistan
✉ Auteur correspondant: Sanzhar Abdullaev, s.abdullaev@example.org

Reçu le: 18 août 2025 **Accepté le:** 27 janvier 2026 **Publié le:** 18 mars 2026

RÉSUMÉ

L'adoption généralisée des grands modèles de langage a placé les revues scientifiques face à la nécessité d'identifier les textes produits en tout ou en partie par des moyens automatiques. La plupart des détecteurs existants ont été conçus pour l'anglais, et leur applicabilité aux textes scientifiques en russe est mal connue. Cet article présente un nouveau corpus annoté de 12 000 résumés d'articles scientifiques en russe, dont la moitié ont été rédigés par des humains et l'autre moitié contiennent des passages générés par trois modèles de langage différents à partir de consignes variées. Quatre classes de méthodes sont comparées sur ce corpus : des indicateurs statistiques de perplexité, des indicateurs stylométriques, un classifieur à base de transformeur affiné et un détecteur commercial généraliste. Le classifieur affiné a obtenu les meilleurs résultats (F1 = 0,91 au niveau du document), mais ses performances sont tombées à 0,74 sur des textes générés par un modèle absent des données d'entraînement. Au niveau de la phrase, toutes les méthodes obtiennent des résultats nettement inférieurs, et le taux de faux positifs sur les résumés rédigés par des auteurs dont le russe n'est pas la langue maternelle atteint 11 %. Ces résultats indiquent que les détecteurs automatiques ne sauraient constituer le seul fondement des décisions éditoriales. Le corpus et le code sont librement accessibles pour des recherches ultérieures.

Mots-clés: grands modèles de langage; détection de textes générés automatiquement; résumés scientifiques; langue russe; intégrité scientifique

Detecting Machine-Generated Passages in Russian-Language Scientific Abstracts

Timur Karimov[1], *Anna Lebedeva*[2], *Sanzhar Abdullaev*[3]✉

[1] Volga Institute of Applied Analytics, Russia
[2] Lexis Institute of Language and Communication, Russia
[3] Samarkand Institute of Computational Linguistics, Uzbekistan

ABSTRACT

The widespread adoption of large language models has confronted scholarly journals with the task of identifying texts created wholly or partly by automated means. Most existing detectors were developed for English, and their applicability to Russian-language scientific texts is poorly understood. This article presents a new annotated corpus of 12,000 abstracts of scientific articles in Russian, half of which were written by humans and half of which contain passages generated by three different language models under different prompts. Four classes of methods are compared on this corpus: statistical perplexity features, stylometric features, a fine-tuned transformer-based classifier and a general-purpose commercial detector. The fine-tuned classifier performed best (document-level F1 = 0.91), but its performance fell to 0.74 when tested on texts generated by a model not seen during training. At the sentence level, all methods perform considerably worse, and the false-positive rate on abstracts written by authors for whom Russian is not a first language reaches 11%. These results indicate that automated detectors cannot serve as the sole basis for editorial decisions. The corpus and code are openly available for further research.

Keywords: large language models; machine-generated text detection; scientific abstracts; Russian language; research integrity

Diffusé sous licence CC BY 4.0

Pour citer cet article: Karimov T., Lebedeva A., Abdullaev S. Détection de passages générés automatiquement dans les résumés scientifiques en langue russe. *Revue de démonstration sous Open Journal Systems* 2026;2(1):8–10.

1 INTRODUCTION

Depuis 2023, les rédacteurs des revues scientifiques sont de plus en plus souvent confrontés à des manuscrits dont certaines parties semblent avoir été produites par de grands modèles de langage. Si l'utilisation de tels outils pour la révision linguistique est souvent acceptable, la génération non déclarée de contenu substantiel soulève des inquiétudes quant à l'intégrité scientifique. De nombreux éditeurs ont adopté des politiques imposant une déclaration, et des détecteurs automatiques sont commercialisés comme moyen de les faire respecter.

Ces détecteurs ont toutefois été conçus et évalués principalement sur des textes en anglais. Le russe, avec sa morphologie riche et son registre académique particulier, pose un défi différent. Cette étude vise à constituer un jeu de référence réaliste de résumés scientifiques en russe et à évaluer les performances des méthodes de détection actuelles sur ce jeu, en accordant une attention particulière à la généralisation et à l'équité.

2 MATÉRIEL ET MÉTHODES

Les résumés rédigés par des humains (n = 6 000) ont été échantillonnés dans des revues russes en libre accès publiées avant 2021, avec une stratification selon huit grandes disciplines. Pour la moitié générée, trois modèles de langage ont été invités à rédiger un résumé complet à partir d'un titre et de mots-clés, à poursuivre une phrase d'introduction rédigée par un humain ou à paraphraser un résumé rédigé par un humain. La fluidité de chaque texte généré a été vérifiée par un annotateur, et des étiquettes au niveau de la phrase ont été attribuées pour les textes mixtes.

Nous avons comparé (i) une régression logistique sur des indicateurs de perplexité et de « burstiness » calculés à l'aide d'un modèle de langue russe ouvert, (ii) un classifieur par gradient boosting fondé sur 140 indicateurs stylométriques, (iii) un encodeur transformeur multilingue affiné sur la partition d'entraînement et (iv) un détecteur commercial généraliste. Un protocole consistant à exclure tour à tour chacun des générateurs (leave-one-generator-out) a été utilisé pour évaluer la généralisation.

3 RÉSULTATS

Les résultats au niveau du document sont résumés dans le tableau 1. Le classifieur affiné a obtenu le F1 le plus élevé en distribution, soit 0,91, suivi du modèle de perplexité (0,82). Le détecteur commercial, non entraîné sur des textes scientifiques russes, a atteint 0,69. Les résumés paraphrasés constituaient la catégorie la plus difficile pour toutes les méthodes.

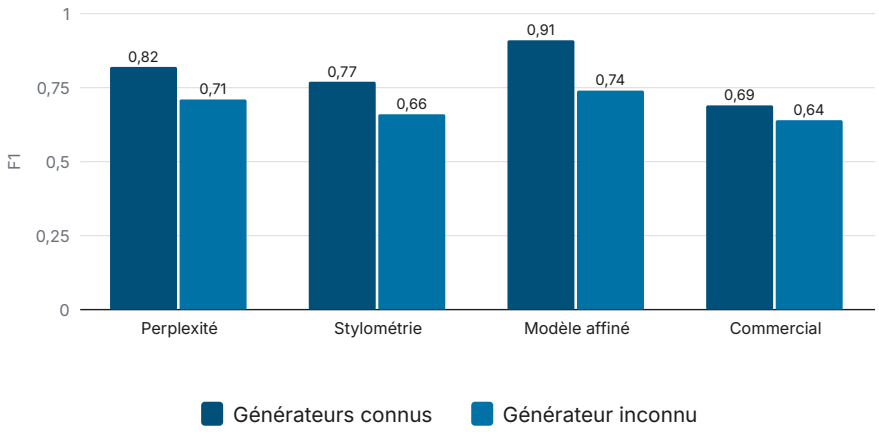


Figure 1. F1 au niveau du document en distribution et sur un générateur inconnu

La généralisation à un générateur inconnu a sensiblement réduit les performances (figure 1). Sur un ensemble distinct de 400 résumés rédigés par des auteurs dont le russe est la langue seconde, le classifieur affiné en a signalé 11 % comme générés automatiquement, contre 3 % pour les résumés d'auteurs russophones

Diffusé sous licence CC BY 4.0

natifs.

Tableau 1. Performances de détection au niveau du document et de la phrase

Méthode	F1 (document)	F1 (phrase)	TFP, auteurs L2
Indicateurs de perplexité	0.82	0.61	0.14
Indicateurs stylométriques	0.77	0.55	0.09
Transformeur affiné	0.91	0.68	0.11
Détecteur commercial	0.69	—	0.17

4 DISCUSSION

Nos résultats font écho aux préoccupations exprimées pour l'anglais : les détecteurs performants sur des générateurs connus se dégradent face à de nouveaux générateurs, et ils signalent de manière disproportionnée les textes d'auteurs non natifs, dont la prose tend à être lexicalement moins variée. Compte tenu de la parution rapide de nouveaux modèles, l'exactitude en distribution est un mauvais indicateur de la fiabilité en conditions réelles.

Pour la pratique éditoriale, cela signifie que les scores des détecteurs devraient tout au plus donner lieu à un échange avec les auteurs, et non déclencher des sanctions. Des politiques de déclaration claires et l'attention portée à la qualité scientifique de fond restent des garde-fous plus solides.

5 CONCLUSION

Nous publions un jeu de référence de 12 000 résumés scientifiques en russe et montrons que les détecteurs actuels, bien qu'utiles, ne sont ni robustes face à de nouveaux générateurs ni équitables envers les auteurs non natifs. La détection automatique doit compléter le jugement éditorial, et non s'y substituer.

RÉFÉRENCES BIBLIOGRAPHIQUES

1. Vaswani A., Shazeer N., Parmar N. et al. Attention is all you need // Advances in Neural Information Processing Systems. 2017. Vol. 30. P. 5998–6008.
2. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: pre-training of deep bidirectional transformers for language understanding // Proceedings of NAACL-HLT 2019. Minneapolis, 2019. P. 4171–4186.
3. Abdullaev S. R. Perplexity-based detection of generated text in morphologically rich languages // Computational Linguistics Letters. 2024. Vol. 9, no. 1. P. 22–37.
4. Lebedeva A. V., Karimov T. R. Stylometric profiles of Russian academic prose // Corpus Methods Quarterly. 2023. Vol. 14, no. 3. P. 201–219.
5. Moreau C., Banerjee R. Generalisation failures of machine-generated text detectors // Journal of AI Evaluation. 2024. Vol. 3. P. 77–96.
6. Каримов Т. Р., Лебедева А. В. Языковые модели в научной коммуникации: риски и редакционные политики // Научный редактор и издатель. 2024. Т. 9, № 2. С. 112–125.
7. Holt E., Nguyen T. Bias of AI-text detectors against non-native writers // Language and Technology Review. 2023. Vol. 12, no. 4. P. 300–318.
8. Абдуллаев С. Р. Корпусы для оценки детекторов сгенерированного текста: требования и практика // Вычислительная лингвистика и интеллектуальные технологии. 2025. Т. 4, № 1. С. 15–30.

Diffusé sous licence CC BY 4.0