TSIFRA, LDA.
Revista de Investigação Interdisciplinar (Demo)
Vol. 2, n.º 1 (2026)
pp. 8–10 · ISSN 0000-0000 (em linha)

ARTIGO DE INVESTIGAÇÃO

Deteção de passagens geradas automaticamente em resumos científicos de língua russa

Timur Karimov[1], **Anna Lebedeva**[2], **Sanzhar Abdullaev**[3]✉

[1] Instituto de Análise Aplicada do Volga, Rússia
[2] Instituto de Língua e Comunicação Lexis, Rússia
[3] Instituto de Linguística Computacional de Samarcanda, Uzbequistão
✉ Autor correspondente: Sanzhar Abdullaev, s.abdullaev@example.org

Recebido: 18 de agosto de 2025 **Aceite:** 27 de janeiro de 2026 **Publicado:** 18 de março de 2026

RESUMO

A ampla adoção dos grandes modelos de linguagem colocou as revistas científicas perante a tarefa de identificar textos criados total ou parcialmente por meios automáticos. A maioria dos detetores existentes foi desenvolvida para o inglês, e a sua aplicabilidade a textos científicos em russo é pouco conhecida. Este artigo apresenta um novo corpus anotado de 12 000 resumos de artigos científicos em russo, metade dos quais foi escrita por pessoas e a outra metade contém passagens geradas por três modelos de linguagem diferentes com diferentes instruções (prompts). Neste corpus, comparam-se quatro classes de métodos: características estatísticas de perplexidade, características estilométricas, um classificador baseado em transformers com afinação (fine-tuning) e um detetor comercial de uso geral. O classificador afinado obteve o melhor desempenho (F1 ao nível do documento = 0,91), mas este desceu para 0,74 quando testado com textos gerados por um modelo não visto durante o treino. Ao nível da frase, todos os métodos têm um desempenho consideravelmente pior, e a taxa de falsos positivos em resumos escritos por autores cuja língua materna não é o russo atinge 11%. Estes resultados indicam que os detetores automáticos não podem servir de base única para as decisões editoriais. O corpus e o código estão disponíveis em acesso aberto para investigação futura.

Palavras-chave: grandes modelos de linguagem; deteção de texto gerado automaticamente; resumos científicos; língua russa; integridade científica

Detecting Machine-Generated Passages in Russian-Language Scientific Abstracts

Timur Karimov[1], *Anna Lebedeva*[2], *Sanzhar Abdullaev*[3]✉

[1] Volga Institute of Applied Analytics, Russia
[2] Lexis Institute of Language and Communication, Russia
[3] Samarkand Institute of Computational Linguistics, Uzbekistan

ABSTRACT

The widespread adoption of large language models has confronted scholarly journals with the task of identifying texts created wholly or partly by automated means. Most existing detectors were developed for English, and their applicability to Russian-language scientific texts is poorly understood. This article presents a new annotated corpus of 12,000 abstracts of scientific articles in Russian, half of which were written by humans and half of which contain passages generated by three different language models under different prompts. Four classes of methods are compared on this corpus: statistical perplexity features, stylometric features, a fine-tuned transformer-based classifier and a general-purpose commercial detector. The fine-tuned classifier performed best (document-level F1 = 0.91), but its performance fell to 0.74 when tested on texts generated by a model not seen during training. At the sentence level, all methods perform considerably worse, and the false-positive rate on abstracts written by authors for whom Russian is not a first language reaches 11%. These results indicate that automated detectors cannot serve as the sole basis for editorial decisions. The corpus and code are openly available for further research.

Keywords: large language models; machine-generated text detection; scientific abstracts; Russian language; research integrity

Licenciado ao abrigo da CC BY 4.0

Como citar: Karimov T., Lebedeva A., Abdullaev S. Deteção de passagens geradas automaticamente em resumos científicos de língua russa. *Revista de demonstração em Open Journal Systems* 2026;2(1):8–10.

1 INTRODUÇÃO

Desde 2023, os editores de revistas científicas deparam-se cada vez mais com manuscritos em que partes do texto parecem ter sido produzidas por grandes modelos de linguagem. Embora a utilização destas ferramentas para a revisão linguística seja muitas vezes aceitável, a geração não declarada de conteúdo substantivo suscita preocupações quanto à integridade científica. Muitas editoras adotaram políticas que exigem a sua declaração, e os detetores automáticos são comercializados como meio de as fazer cumprir.

Estes detetores, porém, foram desenvolvidos e avaliados sobretudo com textos em inglês. O russo, com a sua morfologia rica e o seu registo académico característico, coloca um desafio diferente. Os objetivos deste estudo são construir um conjunto de referência (benchmark) realista de resumos científicos em língua russa e avaliar o desempenho dos métodos de deteção atuais neste conjunto, com especial atenção à generalização e à equidade.

2 MATERIAIS E MÉTODOS

Os resumos escritos por pessoas (n = 6000) foram amostrados de revistas russas de acesso aberto publicadas antes de 2021, estratificados por oito grandes áreas disciplinares. Para a metade gerada, três modelos de linguagem receberam instruções para escrever um resumo completo a partir de um título e de palavras-chave, para continuar uma frase inicial escrita por uma pessoa ou para parafrasear um resumo escrito por uma pessoa. Cada texto gerado foi verificado por um anotador quanto à fluência, e para os textos mistos foram registadas etiquetas ao nível da frase.

Comparámos (i) uma regressão logística sobre características de perplexidade e de irregularidade (burstiness) calculadas com um modelo de linguagem russo aberto, (ii) um classificador de gradient boosting sobre 140 características estilométricas, (iii) um codificador transformer multilingue afinado na partição de treino e (iv) um detetor comercial de uso geral. Para avaliar a generalização, utilizou-se um protocolo de exclusão de um gerador de cada vez (leave-one-generator-out).

3 RESULTADOS

Os resultados ao nível do documento são sintetizados no quadro 1. O classificador afinado obteve o F1 mais elevado na distribuição de treino, de 0,91, seguido do modelo de perplexidade (0,82). O detetor comercial, não treinado com texto científico russo, atingiu 0,69. Os resumos parafraseados foram a categoria mais difícil para todos os métodos.

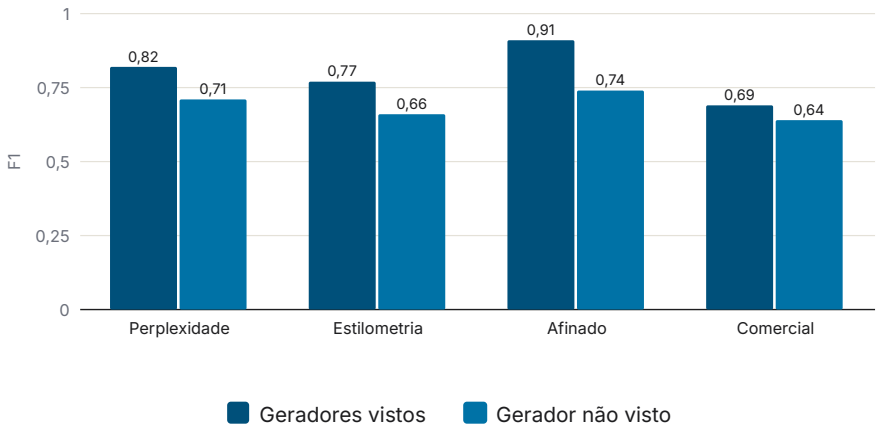


Fig. 1. F1 ao nível do documento na distribuição de treino e com um gerador não visto

A generalização a um gerador não visto reduziu substancialmente o desempenho (fig. 1). Num conjunto separado de 400 resumos escritos por autores para quem o russo é uma segunda língua, o classificador afinado assinalou 11% como gerados automaticamente, face a 3% nos resumos de falantes nativos.

Licenciado ao abrigo da CC BY 4.0

Quadro 1. Desempenho da deteção ao nível do documento e da frase

Método	F1 (doc.)	F1 (frase)	TFP, autores L2
Características de perplexidade	0.82	0.61	0.14
Características estilométricas	0.77	0.55	0.09
Transformer afinado	0.91	0.68	0.11
Detetor comercial	0.69	—	0.17

4 DISCUSSÃO

Os nossos resultados vão ao encontro das preocupações levantadas para o inglês: os detetores que têm bom desempenho com geradores conhecidos degradam-se com geradores novos e assinalam de forma desproporcionada os textos de autores não nativos, cuja escrita tende a ser lexicalmente menos variada. Dado o ritmo acelerado de lançamento de novos modelos, a exatidão na distribuição de treino é um mau indicador da fiabilidade em condições reais.

Para a prática editorial, isto significa que as pontuações dos detetores devem, no máximo, motivar um diálogo com os autores, e não desencadear sanções. Políticas de declaração claras e a atenção à qualidade científica substantiva continuam a ser salvaguardas mais robustas.

5 CONCLUSÃO

Disponibilizamos um conjunto de referência de 12 000 resumos científicos em russo e mostramos que os detetores atuais, embora úteis, não são robustos face a novos geradores nem equitativos para os autores não nativos. A deteção automática deve complementar, e não substituir, o juízo editorial.

REFERÊNCIAS BIBLIOGRÁFICAS

1. Vaswani A., Shazeer N., Parmar N. et al. Attention is all you need // Advances in Neural Information Processing Systems. 2017. Vol. 30. P. 5998–6008.
2. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: pre-training of deep bidirectional transformers for language understanding // Proceedings of NAACL-HLT 2019. Minneapolis, 2019. P. 4171–4186.
3. Abdullaev S. R. Perplexity-based detection of generated text in morphologically rich languages // Computational Linguistics Letters. 2024. Vol. 9, no. 1. P. 22–37.
4. Lebedeva A. V., Karimov T. R. Stylometric profiles of Russian academic prose // Corpus Methods Quarterly. 2023. Vol. 14, no. 3. P. 201–219.
5. Moreau C., Banerjee R. Generalisation failures of machine-generated text detectors // Journal of AI Evaluation. 2024. Vol. 3. P. 77–96.
6. Каримов Т. Р., Лебедева А. В. Языковые модели в научной коммуникации: риски и редакционные политики // Научный редактор и издатель. 2024. Т. 9, № 2. С. 112–125.
7. Holt E., Nguyen T. Bias of AI-text detectors against non-native writers // Language and Technology Review. 2023. Vol. 12, no. 4. P. 300–318.
8. Абдуллаев С. Р. Корпусы для оценки детекторов сгенерированного текста: требования и практика // Вычислительная лингвистика и интеллектуальные технологии. 2025. Т. 4, № 1. С. 15–30.

Licenciado ao abrigo da CC BY 4.0