ООО «ЦИФРА»
Вестник междисциплинарных исследований (демоверсия)
Т. 2, № 1 (2026)
С. 8–10 · ISSN 0000-0000 (онлайн)

НАУЧНАЯ СТАТЬЯ

Распознавание машинно сгенерированных фрагментов в русскоязычных научных аннотациях

Тимур Каримов[1], **Анна Лебедева**[2], **Санжар Абдуллаев**[3]✉

[1] Волжский институт прикладной аналитики, Россия
[2] Институт языка и коммуникации «Лексис», Россия
[3] Самаркандский институт вычислительной лингвистики, Узбекистан
✉ Автор для переписки: Санжар Абдуллаев, s.abdullaev@example.org

Поступила: 18.08.2025 **Принята:** 27.01.2026 **Опубликована:** 18.03.2026

АННОТАЦИЯ

Широкое распространение больших языковых моделей поставило перед научными журналами задачу выявления текстов, полностью или частично созданных автоматически. Большинство существующих детекторов разработаны для английского языка, и их применимость к русскоязычным научным текстам изучена слабо. В статье представлен новый размеченный корпус из 12 тыс. аннотаций научных статей на русском языке, в котором половина текстов написана людьми, а половина содержит фрагменты, сгенерированные тремя различными языковыми моделями с разными инструкциями. На этом корпусе сравниваются четыре класса методов: статистические признаки перплексии, стилометрические признаки, дообученный классификатор на основе трансформера и коммерческий детектор общего назначения. Наилучшие результаты показал дообученный классификатор (F1 = 0,91 на уровне документа), однако его качество снижалось до 0,74 при тестировании на текстах, сгенерированных моделью, не встречавшейся при обучении. На уровне отдельных предложений все методы работают существенно хуже, а доля ложных срабатываний на аннотациях, написанных авторами, для которых русский язык не является родным, достигает 11 %. Эти результаты свидетельствуют о том, что автоматические детекторы не могут служить единственным основанием для редакционных решений. Корпус и код опубликованы в открытом доступе для дальнейших исследований.

Ключевые слова: большие языковые модели; детекция сгенерированного текста; научные аннотации; русский язык; академическая этика

Detecting Machine-Generated Passages in Russian-Language Scientific Abstracts

Timur Karimov[1], *Anna Lebedeva*[2], *Sanzhar Abdullaev*[3]✉

[1] Volga Institute of Applied Analytics, Russia
[2] Lexis Institute of Language and Communication, Russia
[3] Samarkand Institute of Computational Linguistics, Uzbekistan

ABSTRACT

The widespread adoption of large language models has confronted scholarly journals with the task of identifying texts created wholly or partly by automated means. Most existing detectors were developed for English, and their applicability to Russian-language scientific texts is poorly understood. This article presents a new annotated corpus of 12,000 abstracts of scientific articles in Russian, half of which were written by humans and half of which contain passages generated by three different language models under different prompts. Four classes of methods are compared on this corpus: statistical perplexity features, stylometric features, a fine-tuned transformer-based classifier and a general-purpose commercial detector. The fine-tuned classifier performed best (document-level F1 = 0.91), but its performance fell to 0.74 when tested on texts generated by a model not seen during training. At the sentence level, all methods perform considerably worse, and the false-positive rate on abstracts written by authors for whom Russian is not a first language reaches 11%. These results indicate that automated detectors cannot serve as the sole basis for editorial decisions. The corpus and code are openly available for further research.

Распространяется по лицензии CC BY 4.0

Keywords: large language models; machine-generated text detection; scientific abstracts; Russian language; research integrity

Для цитирования: Каримов Т., Лебедева А., Абдуллаев С. Распознавание машинно сгенерированных фрагментов в русскоязычных научных аннотациях // Демоверсия журнала на Open Journal Systems 2026. Т. 2, № 1. С. 8–10.

1 ВВЕДЕНИЕ

С 2023 г. редакторы научных журналов всё чаще сталкиваются с рукописями, части текста которых, по всей видимости, созданы большими языковыми моделями. Хотя использование таких инструментов для языкового редактирования нередко допустимо, нераскрытое генерирование содержательной части текста вызывает опасения с точки зрения научной добросовестности. Многие издатели приняли правила, требующие раскрытия такого использования, а автоматические детекторы продвигаются на рынке как средство контроля за их соблюдением.

Однако эти детекторы разрабатывались и оценивались преимущественно на англоязычных текстах. Русский язык с его богатой морфологией и своеобразным академическим регистром представляет собой иную задачу. Цели настоящего исследования — создать реалистичный эталонный набор русскоязычных научных аннотаций и оценить эффективность современных методов детекции на нём, уделив особое внимание обобщающей способности и справедливости.

2 МАТЕРИАЛЫ И МЕТОДЫ

Аннотации, написанные людьми (n = 6 000), отобраны из русскоязычных журналов открытого доступа, опубликованных до 2021 г., со стратификацией по восьми укрупнённым дисциплинам. Для генерированной половины набора трём языковым моделям давались инструкции написать полную аннотацию по названию и ключевым словам, продолжить написанное человеком первое предложение или перефразировать написанную человеком аннотацию. Каждый сгенерированный текст проверялся разметчиком на гладкость, а для смешанных текстов фиксировались метки на уровне предложений.

Мы сравнили: (i) логистическую регрессию на признаках перплексии и «взрывности» (burstiness), вычисленных с помощью открытой русскоязычной языковой модели; (ii) классификатор на основе градиентного бустинга по 140 стилометрическим признакам; (iii) многоязычный трансформерный кодировщик, дообученный на обучающей части выборки; (iv) коммерческий детектор общего назначения. Для оценки обобщающей способности использовался протокол с исключением одного генератора (leave-one-generator-out).

3 РЕЗУЛЬТАТЫ

Результаты на уровне документов обобщены в табл. 1. Наибольшее значение F1 на данных из того же распределения (0,91) показал дообученный классификатор, за ним следует модель на основе перплексии (0,82). Коммерческий детектор, не обучавшийся на русскоязычных научных текстах, достиг 0,69. Перефразированные аннотации оказались наиболее сложной категорией для всех методов.

Распространяется по лицензии CC BY 4.0

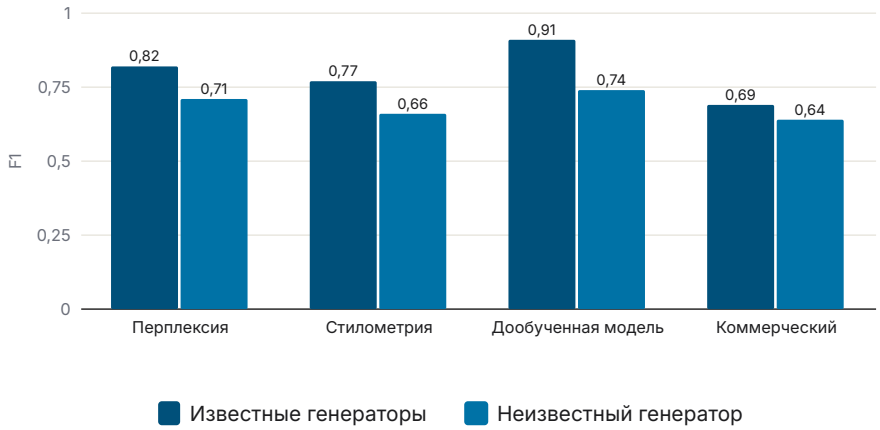


Рис. 1. F1 на уровне документов на данных из того же распределения и для неизвестного генератора

Переход к ранее не встречавшемуся генератору существенно снижал качество (рис. 1). На отдельном наборе из 400 написанных людьми аннотаций авторов, для которых русский язык не является родным, дообученный классификатор пометил как машинно-сгенерированные 11 % текстов против 3 % для аннотаций носителей языка.

Таблица 1. Качество детекции на уровне документов и предложений

Метод	F1 (документ)	F1 (предложение)	FPR, авторы-неносители
Признаки перплексии	0.82	0.61	0.14
Стилометрические признаки	0.77	0.55	0.09
Дообученный трансформер	0.91	0.68	0.11
Коммерческий детектор	0.69	—	0.17

4 ОБСУЖДЕНИЕ

Наши результаты перекликаются с опасениями, высказанными в отношении английского языка: детекторы, хорошо работающие на знакомых генераторах, теряют качество на новых и непропорционально часто помечают тексты авторов, для которых язык не является родным и чья письменная речь, как правило, лексически менее разнообразна. С учётом быстрого выпуска новых моделей точность на данных из того же распределения плохо отражает надёжность в реальных условиях.

Для редакционной практики это означает, что оценки детекторов могут служить в лучшем случае поводом для разговора с авторами, но не основанием для санкций. Чёткие правила раскрытия информации и внимание к содержательному научному качеству остаются более надёжными мерами защиты.

5 ЗАКЛЮЧЕНИЕ

Мы публикуем эталонный набор из 12 000 русскоязычных научных аннотаций и показываем, что современные детекторы, будучи полезными, не устойчивы к новым генераторам и несправедливы по отношению к авторам, для которых язык не является родным. Автоматическая детекция должна дополнять, а не заменять редакционную экспертизу.

СПИСОК ЛИТЕРАТУРЫ

1. Vaswani A., Shazeer N., Parmar N. et al. Attention is all you need // Advances in Neural Information Processing Systems. 2017. Vol. 30. P. 5998–6008.
2. Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: pre-training of deep bidirectional transformers for language understanding // Proceedings of NAACL-HLT 2019. Minneapolis, 2019. P. 4171–4186.

Распространяется по лицензии CC BY 4.0

3. Abdullaev S. R. Perplexity-based detection of generated text in morphologically rich languages // Computational Linguistics Letters. 2024. Vol. 9, no. 1. P. 22–37.
4. Lebedeva A. V., Karimov T. R. Stylometric profiles of Russian academic prose // Corpus Methods Quarterly. 2023. Vol. 14, no. 3. P. 201–219.
5. Moreau C., Banerjee R. Generalisation failures of machine-generated text detectors // Journal of AI Evaluation. 2024. Vol. 3. P. 77–96.
6. Каримов Т. Р., Лебедева А. В. Языковые модели в научной коммуникации: риски и редакционные политики // Научный редактор и издатель. 2024. Т. 9, № 2. С. 112–125.
7. Holt E., Nguyen T. Bias of AI-text detectors against non-native writers // Language and Technology Review. 2023. Vol. 12, no. 4. P. 300–318.
8. Абдуллаев С. Р. Корпусы для оценки детекторов сгенерированного текста: требования и практика // Вычислительная лингвистика и интеллектуальные технологии. 2025. Т. 4, № 1. С. 15–30.

Распространяется по лицензии CC BY 4.0